Escola de Matemática Aplicada

Aula Prática 5 - ALN - Fatoração QR

Aluno: *Gustavo Murilo Cavalcante Carvalho*

E-mail: *gustavomurilo012@gmail.com*

Programa: *Bacharelado em Matemática Aplicada*

Disciplina: *Álgebra Linear Numérica*

Professor: *Antonio Carlos Saraiva Branco*

Data: *14 de junho de 2024*

Sumário

Problema 1

O método de Gram Schmidt para ortogonalização de vetores é um método iterativo que, dado um conjunto de vetores linearmente independentes, gera um conjunto de vetores ortogonais. O método é baseado na projeção de um vetor sobre os vetores anteriores.

Implementação

qr_GS.m

```
% Entradas:
%   A - matriz (m x n)
% Saídas:
%   Q = matriz (m x n) ortogonal
%   R = matriz (n x n) triangular superior
function [Q,R] = qr_GS(A)
  [m, n] = size(A);

  % Inicializa matrizes
  Q = zeros(m,n);
  R = zeros(n);

  for j = 1 : n
    v = A(:,j); % j-ésima coluna de A

    % Obtém, por Gram-Schmidt, v o j-ésimo vetor de uma base ortogonal
    for i = 1 : j-1
      R(i,j) = dot(Q(:,i), A(:,j));
      v = v - R(i,j) * Q(:,i);
    end

    R(j,j) = norm(v,2);
    Q(:,j) = v / R(j,j); % j-ésimo vetor de uma base ortonormal
  end
end
```

Testes

A seguir estão algumas matrizes selecionadas para testar as funções implementadas neste trabalho.

$$A = \begin{bmatrix} 1 & 2 & 2 \\ -1 & 1 & 2 \\ -1 & 0 & 1 \\ 1 & 1 & 2 \end{bmatrix} \quad B = \begin{bmatrix} 16 & 2 & 3 & 13 \\ 5 & 11 & 10 & 8 \\ 9 & 7 & 6 & 12 \\ 4 & 14 & 15 & 1 \end{bmatrix} \quad C = \begin{bmatrix} 2 & 1 & 2 & 4 \\ 3 & 1 & 2 & 2 \end{bmatrix}$$

A é uma matriz ideal para ortogonalização (tanto que é um exemplo dado pelo Poole), pois possui vetores linearmente independentes.

B é uma matriz mágica de ordem par, portanto é muito má condicionada, o que é interessante para os testes.

C é uma matriz retangular com mais colunas do que linhas, o que não é o caso esperado de acordo com a apresentação da fatoração QR (a que é feita no Poole), contudo é um cenário de prova para a implementação e interpretação do método.

Testando para o cenário ideal (a matriz A), temos:

```
>> [QCa, RCa] = qr_GS(A);

QCa =
    0.5    0.67082   -0.40825
   -0.5    0.67082          0
   -0.5    0.22361    0.40825
    0.5    0.22361     0.8165

RCa =
    2          1        0.5
    0     2.2361     3.3541
    0          0     1.2247
```

Considerando $A = QR$, para verificar a ortogonalidade de Q, calculamos Q^TQ e para verificar a acurácua decomposição QR, calculamos $QR - A$.

```
>> QCa'*QCa
    1          0          0
    0          1   -2.7e-17
    0   -2.7e-17          1

>> QCa*RCa - A
    0    0    0
    0    0    0
    0    0    0
    0    0    0
```

Pode ser visto que a decomposição QR obtida foi muito boa. Q não é por muito pouco (o erro é irrelevante, tem grandeza 10^{-17}) a indentidade, e a multiplicação de Q e R resulta em A.

Para as outras matrizes (B e C), temos:

Ambas são boas fatorações, afinal a multiplicação das matrizes resulta na matriz original, ou algo muito próximo disso.

```
>> QCc*RCc - C
   -2.2e-16    0    0    0
          0    0    0    0

>> QCb*RCb - B
    0    0    0    0
    0    0    0    0
    0    0    0    0
    0    0    0    0
```

Testando a ortogonalidade de B, vemos que o resultado não é o melhor, muitas entradas são muito próximas de zero, outras nem tanto (na ordem de 10^{-1}). Isso é uma consequência do mal condicionamento de B.

```
>> QCb'*QCb
          1   -2.7e-17    4.9e-16    0.55125
   -2.7e-17          1   -5.5e-16   -0.25841
    4.9e-16   -5.5e-16          1    -0.7925
    0.55125   -0.25841    -0.7925          1
```

Para C, temos que avaliar algo diferente, afinal a matriz Q associada a ela não pode ser ortogonal, ela não é LI. Note que há um bloco que é a indentidade, o que acontece devido ao fato de que os dois primeiros vetores são LI, se fossem outros, o bloco da identidadde estaria em outra posição (ao menos é .

```
>> QCc'*QCc
          1    1.4e-15    0.00377    0.00377
    1.4e-15          1   -0.99999   -0.99999
    0.00377   -0.99999          1          1
    0.00377   -0.99999          1          1

>> QCc(1:2, 1:2)'*QCc(1:2, 1:2)
          1    1.4e-15
    1.4e-15          1
```

Problema 2

Implementação

qr_GSM.m

```
% Entradas:
%   A - matriz (m x n)
% Saídas:
%   Q = matriz (m x n) ortogonal
%   R = matriz (n x n) triangular superior
function [Q,R] = qr_GSM(A)
  [m, n] = size(A);

  % Inicializa matrizes
  Q = zeros(m,n);
  R = zeros(n);

  for j = 1 : n
    v = A(:,j); % j-ésima coluna de A

    % Obtém, por Gram-Schmidt, v o j-ésimo vetor de uma base ortogonal
    for i = 1 : j-1
      R(i,j) = dot(Q(:,i), v); % Usa o vetor atualizado
      v = v - R(i,j) * Q(:,i);
    end

    R(j,j) = norm(v,2);
    Q(:,j) = v / R(j,j); % j-ésimo vetor de uma base ortonormal
  end
end
```

Testes

Para a matriz A, essa modificação não surtiu efeito algum. Portanto, não há necessidade expor os resultados.

Para a matriz B, uma matriz má condicionada, a modificação alterou minimamente uma entrada da matriz R. Quanto à matriz Q, notamos que a ultima colunas dessa nova Q é diferente da anterior.

```
>> QCb(:,4)' % Quarta coluna da matriz Q obtida com qr_GSC
    0.32233    0.40291    0.64466   -0.56408

>> [QMb, RMb] = qr_GSM(B);

>> QMb(:,4)'
    0.94679    0.063119    0.25248   -0.18936
```

Problema 3

Implementação

qr_GSP.m

```
% Código do problema 3
```

Testes

Problema 4

Implementação

qr_House.m

```
% Entradas:
%   A - matriz de entrada (m x n)
% Saídas:
%   U - matriz (m x m) contendo os vetores normais
%   R - matriz (m x n) triangular superior
function [U, R] = qr_House(A)
  [m, n] = size(A);

  % Inicializar a matriz U com zeros
  U = zeros(m, m);

  for i = 1 : n
    % Extrair a coluna atual a partir da i-ésima linha até o final
    x = A(i:m, i);

    % Obtém o vetor normal ao hiperplano de reflexão
    if x(1) > 0
      x(1) = x(1) + norm(x, 2);
    else
      x(1) = x(1) - norm(x, 2);
    end

    u = x / norm(x, 2); % Normaliza o vetor
    U(i:m, i) = u;  % Armazena o vetor em U

    % Aplica a transformação de Householder à submatriz de A
    A(i:m, i:n) = A(i:m, i:n) - 2*u*(u'*A(i:m, i:n));
  end

  R = triu(A); % Os valores abaixo da diagonal seriam proximos de 0
end
```

qr_House_min.m

```
% Entradas:
%   A - matriz (m x n)
% Saídas:
%   U - matriz (m x n) contendo os vetores normais
%   R - matriz (m x k) triangular superior
function [U,R] = qr_House_min(A)
  [m, n] = size(A);

  % Determina a dimensão correta
  if m == n
    k = m - 1;
  else
    k = min(m,n); % Essa alteração abrange o caso onde m < n
  end

  % Inicializa matrizes
  R = A;
  U = zeros(m, k);

  for i = 1 : min(m,n)
    x = A(i:m, i);

    % Obtém o vetor normal ao hiperplano de reflexão
    if x(1) > 0
      x(1) = x(1) + norm(x, 2);
    else
      x(1) = x(1) - norm(x, 2);
    end

    u = x / norm(x,2); % Normaliza o vetor
    U(i:m, i) = u;     % Armazena o vetor em U

    % Aplica a transformação de Householder à submatriz de A
    A(i:m, i:n) = A(i:m, i:n) - 2*u*(u'*A(i:m, i:n));
  end

  R = triu(A(1:k, 1:n)); % Para que coincida com
end %endfunction
```

constroi_Q.m

```
% Entradas:
%   U - matriz (m x n) com vetores de Householder
% Saídas:
%   Q = matriz (m x n) ortogonal
function [Q] = constroi_Q(U)
  % Obtém dimensões de U e inicializa Q
  [m,n] = size(U);
  Q = eye(m,n);

  for i = 1 : n
    u = U(:,i);

    % Aplica a tranformação de Householder pela direita Q*(H - u*u')
    Q = Q - 2*Q*(u*u');
  end
end
```

Testes

Problema 5

Implementação

espectro.m

```
% Entradas:
%   A - matriz (n x n)
% Saídas:
%   S = vetor (n x 1) ortogonal
function [S] = espectro(A, tol)
  % Definição de variáveis
  erro = tol + 1;
  S = diag(A);

  while tol <= erro
    % Processo iterativo
    [Q, R] = qr_GSM(A);
    A = R * Q;

    % Verificação de convergência
    novo_S = diag(A);
    erro = norm(S - novo_S,'inf');

    S = novo_S; % Atualiza o resultado
  end
end
```

Testes

Para os testes, gero matrizes com números inteiros uniformemente distribuídos entre 1 e 9. A matriz é então multiplicada por sua transposta para que seja simétrica e, portanto, tenha autovalres reais. Então comparamos os autovalores obtidos pela função criada com os autovalores obtidos pela função `eig` do MATLAB.

```
>> M = randi(9,5,5);

>> M = M' * M;

>> flip(eig(M))
    606.58    61.75    29.118    4.9587    0.58848

>> S = espectro(M, 1e-12)
    606.58    61.75    29.118    4.9587    0.58848
```

Os testes acima (assim como todos os posteriores) foram feitos com uma tolerância de $10^{\{-12\}}$, e mesmo assim foram obtidos muito rapidamente.

Uma ideia interessante para escalar os testes para matrizes maiores, é verificar a norma entre a diferença do resultado das funções, ao invés de comparar os vetores diretamente.

```
>> N = randi(9,10,10);
>> N = N' * N;
>> S = espectro(N, 1e-12);
>> S - flip(eig(N))
    9.0949e-13
   -8.5265e-14
    1.4211e-14
   -1.4211e-14
    5.6843e-14
    3.5527e-14
   -1.3603e-11
    1.3443e-11
   -3.1974e-14
    1.9054e-13

>> norm(espectro(N,1e-12) - flip(eig(N)))
    1.9148e-11
```

Verificando para uma matriz de ordem 100, temos:

```
>> O = randi(9,200,200)
>> O = O' * O;
>> norm(espectro(O,1e-12) - flip(eig(O)))
    7.5866e-10
```

Esse resultado foi bem precismo, mas a função já demorou bem mais para convergir (aproximadamente 1 minuto).

Para matrizes maiores (de ordem 300 por exemplo), a nossa função passa a ser muito lenta (demorando quase 6 minutos para convergir) o que torna o seu uso inviável.